# **PROJET OSINT EBAY**

# **Groupe 7**

Donovan FERRE, Nathan MICHEL, Nassem AHMED, Bérenger DESGARDIN

# Sujet choisi:

Récupérer les données liées aux automobiles sur le site d'Ebay

## In [1]:

```
import requests
from bs4 import BeautifulSoup
import pandas as pd
from datetime import datetime
from dateutil import parser
import time
from urllib import request
import csv
import re

from selenium import webdriver
from selenium.webdriver.common.keys import Keys
from selenium.webdriver.support.ui import WebDriverWait
from selenium.webdriver.support import expected_conditions as EC
from selenium.webdriver.common.by import By
from selenium.webdriver.common.action_chains import ActionChains
```

#### In [2]:

```
# Pour DL Chromedriver : https://sites.google.com/a/chromium.org/chromedriver/
# Pour DL Chromedriver : https://github.com/mozilla/geckodriver/releases
```

#### In [3]:

```
vehicules = []
attributs = []
attributs_labels = []
en_tete = True
```

### In [4]:

```
label_validators = {
    'Prix': float,
    'État': str,
    'Kilométrage': int,
    'Nombre de portes': int,
    'Année' : int,
    'Nombre de places': int,
    'Type': str,
    'Equipements de Confort': str,
    'Couleur': str,
    'Boîte de Vitesse': str,
    'Equipements de Sécurité': str,
    'Puissance (ch DIN)': int,
    'Equipements Extérieurs': str,
    'Modèle': str,
    'Carnet d\'entretien disponible': str,
    'Equipements Audio & Navigation': str,
    'Date de 1ère immatriculation': int,
    'Constructeur': str,
    'Marque': str,
    'Objet modifié': str,
    'Carburant': str,
    'Lien': str
}
def validator(label, value):
    if label in label_validators.keys():
        if type(label validators[label](value)) is label validators[label]:
            return label validators[label](value)
    return "NaN"
```

### In [5]:

```
def SaveInCsv(en_tete):
    for x in range(len(vehicules)):
        ligne = []
        vehicule_clean = {}
        vehicule = vehicules[x]
        for attribut_label in attributs_labels:
            ok = False
            for label in vehicule:
                if attribut label == label:
                    ligne.append(vehicule[label])
                    ok = True
                    break
            if ok == False:
                ligne.append("")
                  print(None)
#
        with open('ebayData.csv', 'a', encoding="utf-8", newline='') as csvfile:
            spamwriter = csv.writer(csvfile, delimiter=';')
            if en tete==True:
                spamwriter.writerow(attributs_labels)
                en_tete = False
            spamwriter.writerow(ligne)
    return en_tete
```

#### In [6]:

```
html = None
# TROP SECURE
# url = 'https://www.leboncoin.fr/'
url = 'https://www.ebay.fr/'
# https://www.ebay.fr/b/Automobiles-et-motocyclettes/9800/bn_16549400
id = 'gh-ac'
selector = 'title'
# PATH a modifier en fonction de la machine
chrome options = webdriver.ChromeOptions()
# chrome options.add argument('--headless')
chrome_options.add_argument('--disable-extensions')
chrome options.add argument('--profile-directory=Default')
chrome options.add argument("--incognito")
chrome options.add argument("--disable-plugins-discovery");
chrome_options.add_argument("--start-maximized")
browser = webdriver.Chrome('C:/Users/beren/Desktop/chromedriver.exe', options=chrome op
tions)
# PATH a modifier en fonction de la machine
# from selenium.webdriver.firefox.firefox binary import FirefoxBinary
# monExecutable = FirefoxBinary('C:/Program Files/Mozilla Firefox/firefox.exe')
# browser = webdriver.Firefox(firefox binary= monExecutable)
browser.get(url)
search = browser.find element by id(id)
# RECHERCHE SUR 'AUTO'
search.send keys('auto')
search.submit()
# time.sleep(3)
html = browser.page_source
soup = BeautifulSoup(html, 'lxml')
attributs_labels.append('Lien')
attributs labels.append('Prix')
# ON BOUCLE POUR PARCOURIR PLUSIEURS PAGES
nb pages max = 2
page_actuelle = 1
link_pages = soup.find_all(class_='pagination__item', limit=nb_pages_max)
# print(link pages)
for link page in link pages:
     print(link page)
          page = soup.find(class = 'pagination item', text=page actuelle)
          print(page['href'])
    link page href = link page['href']
          On attends que le lien soit clickable
    WebDriverWait(browser, 1).until(EC.element to be clickable((By.XPATH, '//a[@href="'
```

```
+link_page_href+'"]')))
    link = browser.find_element_by_xpath('//a[@href="'+link_page_href+'"]')
    print("Lien de la page : " + str(link_page_href))
    link.click()
#
      soup = BeautifulSoup(page)
#
      html = browser.page_source
      WebDriverWait(browser, timeout).until(EC.presence of element located((By.XPATH,
 '//a[@href="'+link_page_href+'"]')), 'Time out')
      WebDriverWait(browser, 10).until(EC.presence_of_element_located((By.ID, 'mainCont
ent')))
    html = request.urlopen(link page href)
    time.sleep(3)
    soup = BeautifulSoup(html, 'lxml')
    vehicule on page = soup.find all(class ='s-item info clearfix')
      print("Nombre de véhicules : "+ str(len(vehicule on page)))
#
    for item in vehicule on page:
        a = item.find('a', href=True)
        link_href = a['href']
#
          print(link href)
               AFTER PAGE CHANGE
#
          timeout = 10
          WebDriverWait(browser, timeout).until(EC.presence_of_element_located((By.XPAT
  '//a[@href="'+link_page_href+'"]')), 'Time out')
Η,
        #
              On attends que le lien soit clickable
        try:
            link = WebDriverWait(browser, 10).until(EC.element to be clickable((By.XPAT
H, '//a[@href="'+link_href+'"]')), 'Time Out')
                browser.find element by xpath('//a[@href="'+link href+'"]')
            vehicule = {}
            vehicule name = item.find('h3').text
            action=ActionChains(browser)
            action.move_to_element(link).perform()
              print("Element is visible? " + str(link.is_displayed()))
              print("Lien du vehicule : " + str(link href))
#
            link.click()
            try:
                  time.sleep(1)
                x = []
                V = []
                html = browser.page source
                soup = BeautifulSoup(html, 'lxml')
                  print(soup.find(class_ = 'section'))
                section = soup.find(class ='section')
        # #
                    print(section.table)
                prix_span = soup.find(attrs={'itemprop': 'price'})
                prix = prix_span['content']
```

```
prix = float(re.sub('\s', '', prix.replace(' EUR', '').replace(',', '.'
)))
                y.append('Lien')
                x.append(link_href)
                y.append('Prix')
                x.append(prix)
                presentation = section.find('table', attrs={'role': 'presentation'}, id
=None)
                  print(presentation)
                attrLabels = presentation.find all(class = 'attrLabels')
                values = presentation.find_all("td")
                for value in values:
                    attr = value.find("span")
                    if attr:
                        x.append(attr.text)
                for labels in attrLabels:
                    string = labels.text
                    string_clean = string.replace("\t", "")
                    string_clean2 = string_clean.replace("\n", "")
                    string_clean3 = string_clean2.replace(":", "")
                    string_clean4 = string_clean3.replace(";", ".")
                    string_clean5 = string_clean4[1:-1]
                    y.append(string_clean5)
                    if string_clean5 not in attributs_labels:
                        attributs labels.append(string clean5)
                  print(len(y))
                  print(y)
        #
                  print(len(x))
                  print(x)
                for z in range(0, len(x)):
                    label = y[z]
                    value = x[z]
                    vehicule[label] = validator(label, value)
                      vehicule[label] = value
#
                      print(vehicule)
#
                vehicules.append(vehicule)
        #
                  time.sleep(1)
            except:
                  print("Something went wrong")
            finally:
                browser.back()
        except:
              print("Time Out")
    en_tete = SaveInCsv(en_tete)
```

```
# print(attributs_labels)
# print(attributs)
# print(vehicules)
browser.quit()
Lien de la page : https://www.ebay.fr/sch/i.html?_from=R40&_nkw=auto&_saca
t=0& pgn=1
Something went wrong
Lien de la page : https://www.ebay.fr/sch/i.html? from=R40& nkw=auto& saca
t=0& pgn=2
Time Out
Time Out
Something went wrong
Something went wrong
Something went wrong
Something went wrong
Time Out
In [7]:
vehicules_clean = []
# attributs labels
for x in range(len(vehicules)):
    vehicule_clean = {}
    vehicule = vehicules[x]
     print(vehicule)
    for attribut_label in attributs_labels:
        ok = False
        for label in vehicule:
            if attribut_label == label:
                vehicule_clean[attribut_label] = vehicule[label]
                ok = True
                break
        if ok == False:
            vehicule clean[attribut label] = None
      print(vehicule clean)
    vehicules_clean.append(vehicule_clean)
```

# print(vehicules\_clean)

#### In [8]:

```
print(attributs_labels)
```

['Lien', 'Prix', 'État', 'Kilométrage', 'Nombre de portes', 'Année', 'Nombre de places', 'Type', 'Equipements de Confort', 'Couleur', 'Boîte de Vite sse', 'Nombre de propriétaires précédents', 'Carburant', 'Equipements de S écurité', 'Puissance (ch DIN)', 'Equipements Extérieurs', 'Modèle', "Carne t d'entretien disponible", 'Equipements Audio & Navigation', 'Date de 1ère immatriculation', 'Constructeur', 'Marque', 'Durée garantie occasion', 'Da te du Contrôle Technique', 'Objet modifié', 'Date expiration garantie cons tructeur', 'CO2 (g/km)', 'brand', 'mpn', 'Description de la modification', 'Pièces classiques', 'Alimentazione', "Veicolo d'epoca", 'Marca', 'Cambi o', 'Tipo', 'Posti', 'Data di immatricolazione', 'Venditore', 'Modello', 'Type du véhicule']

#### In [9]:

# In [10]:

df.head()

# Out[10]:

	Lien	Prix	État	Kilométrage	Nombre de portes	Année	Nombre de places
0	https://www.ebay.fr/itm/Mercedes- Benz-Classe-S	3000.0	Objet ayant été utilisé. Consulter la descript	249000.0	4.0	2002.0	5.0
1	https://www.ebay.fr/itm/Mercedes- C220/27440717	9600.0	Objet ayant été utilisé. Consulter la descript	136000.0	NaN	2008.0	NaN
2	https://www.ebay.fr/itm/voiture- Toyota-RAV-4-I	4150.0	Objet ayant été utilisé. Consulter la descript	94000.0	NaN	2007.0	NaN
3	https://www.ebay.fr/itm/Mehari- CT-OK/224101793	15000.0	Objet ayant été utilisé. Consulter la descript	10.0	2.0	1977.0	4.0
4	https://www.ebay.fr/itm/FORD- MUSTANG-5-0-GT-FA	6500.0	None	44000.0	NaN	1996.0	NaN

5 rows × 41 columns

In [11]:

df.shape

Out[11]:

(86, 41)

## In [12]:

```
# # DEBUT DE STATS - LAISSE DE COTE
# from statistics import mean, median, mode, stdev
# prixs = df['Prix'].to_numpy()
# prix_moyenne = mean(prixs)
# prix_mediane = median(prixs)
# km = df['Kilométrage'].to_numpy()
# km = list(map(int, km))
# km_moyenne = mean(km)
# km_mediane = median(km)
# année = df['Année'].to_numpy()
# année = list(map(int, année))
# année_moyenne = mean(année)
# d = {'Prix moyen': [prix_moyenne], 'Prix médian': [prix_mediane], 'Kilometrage moye
n': [km_moyenne], 'Kilometrage médian': [km_mediane], 'Année moyenne': [année_moyenne]}
# df2 = pd.DataFrame(data = d)
# df2.head()
```

### In [ ]: